

【中信建投金工及基金研究】“逐鹿”Alpha专题报告（二十）——基于数亿新闻上下文的本地RAG系统用于市场择时及行业轮动

姚紫薇 王超 中信建投金工及基金研究团队 2024年04月29日 16:11 上海

重要提示：通过本订阅号发布的观点和信息仅供中信建投证券股份有限公司（下称“中信建投”）客户中符合《证券期货投资者适当性管理办法》规定的机构类专业投资者参考。因本订阅号暂时无法设置访问限制，若您并非中信建投客户中的机构类专业投资者，为控制投资风险，请您请取消关注，请勿订阅、接收或使用本订阅号中的任何信息。对由此给您造成的不便表示诚挚歉意，感谢您的理解与配合！

核心观点

本研究通过融合新闻数据与先进的大型语言模型，构建了一个本地化的RAG系统。该系统充分利用了大型语言模型在文本总结、分析和推理方面的强大能力，并结合市场新闻和状态信息，以实现一系列复杂下游任务的有效处理。我们依据大型语言模型生成的预测信号，进一步设计并实施了三种策略：市场择时策略、行业轮动策略以及行业轮动+择时的复合策略，三个策略展现出了卓越的表现。

主要内容

简介

本文中，我们探索了将新闻数据与大型语言模型相结合的可能性，构建了一个本地化的RAG系统。该系统依托于大型语言模型的深度分析能力，对新闻数据进行综合处理和分析。

数据

财经新闻数据是金融市场分析和决策的重要基础，提供了市场动态、宏观经济指标、公司业绩等多方面的关键信息。各大财经网站每日均会产生大量的新闻文本数据，为了进一步聚合分析这些数据，需要对新闻文本做一系列处理。

RAG

RAG的主要优势在于其能够提高答案的准确性和相关性。通过引用外部知识库中的信息，RAG可以提供更准确的回答，增加用户信任。此外，RAG便于知识更新和引入特定领域知识，有效解决了知识更新的问题。RAG还可以根据特定领域进行定制，为特定领域提供知识支持。

RAG用于市场分析

传统投资领域的专业人士每日肩负着分析庞杂新闻资讯的重任，这一过程不仅要求投资者具备深厚的专业知识和丰富的实践经验，还需要投入大量的时间和精力进行细致的研读与分析。通过利用大型语言模型（LLM）的先进数据分析和推理能力，结合本地化的检索增强生成（RAG）系统，我们能够高效地执行这一任务。投资者可以根据个性化需求，指导LLM对新闻资讯进行深度分析，并生成相应的分析结果。在本研究中，我们运用LLM对市场趋势进行预测，并制定相应的市场择时和行业轮动策略。

一、简介	1
二、数据	1
2.1 数据简介	1
2.2 数据清洗	2
三、RAG	3
3.1 信息检索-向量数据库	5
3.1.1 文本切分	7
3.1.2 文本嵌入	8
3.1.2 向量数据库	9
3.2 文本生成	10
3.2.1 大模型部署	11
3.2.2 文本生成	14
四、RAG 用于市场分析	15
4.1 LLM 市场择时	15
4.2 LLM 行业轮动	18
4.3 LLM 行业轮动+择时	20
五、总结	21
风险分析	22



一、简介

财经新闻数据构成了金融市场分析和决策的坚实基础，它涵盖了市场动态、宏观经济指标、公司业绩等多维度的关键信息，成为主动投资管理中不可或缺的决策参考。在量化投资的实践中，传统的结构化数据分析方法虽然广泛应用，但面对新闻数据中的非结构化信息，传统算法如情感分析和关联分析等往往只能捕捉到信息的一部分，无法全面挖掘和利用新闻数据的全部价值。

随着大型语言模型技术的兴起，其在金融领域的应用潜力逐渐被挖掘和实现。这些模型以其卓越的文本分析和理解能力，为非结构化信息的处理提供了新的解决方案。本文中，我们探索了将新闻数据与大型语言模型相结合的可能性，构建了一个本地化的RAG（Retrieval-Augmented Generation）系统。该系统依托于大型语言模型的深度分析能力，对新闻数据进行综合处理和分析。

进一步地，我们利用大型语言模型预测的信号，构建了行业轮动和市场择时策略。实证结果显示，结合大型语言模型的分析能力所制定的策略，取得了显著优于基准的表现。这一成果不仅突显了大型语言模型在金融决策中的潜在价值，也为量化投资领域提供了新的研究路径和实践方法。

二、数据

财经新闻数据是金融市场分析和决策的重要基础，提供了市场动态、宏观经济指标、公司业绩等多方面的关键信息。各大财经网站每日均会产生大量的新闻文本数据，为了进一步聚合分析这些数据，需要对新闻文本做一系列处理。

2.1 数据简介

本研究利用聚源数据汇总的各大财经媒体发布的新闻数据。为确保分析数据的新颖性，避免其已被广泛应用于大型模型训练，本研究选取了2023年及以后，主流财经网站发布的新闻文本数据进行分析。数据集总计包含超过50万条新闻样本，日均新闻样本数量的中位数达到1061条。就单条新闻的字段长度而言，中位数为519字，平均值为826字；最长的新闻报道包含超过10万字，而最短的仅含11字。此数据集的广度与深度，为本研究提供了一个丰富的信息源，以支撑后续的分析与探讨。

图 1:新闻数据样例

ID	InfoType	InfoPublDate	MediaCode	Media	Category	InfoTitle	Content	Writer	Author	ObjExtCode	AreaCode
567070174643		2017-12-20 00:00:00	120	聚源数据	71	今日要闻1220	一、宏观【央行】四季度,企业贷款 再减少			1000	142
567075966789		2017-12-20 00:00:00	120	聚源数据	61	基金仓位1220	一、宏观 此轮基金的11月经济数据显示,保贷等 增多			1000	142
567054922845		2017-12-20 00:00:00	2	证券时报	52	下游需求支撑下沪钢 上涨	12月21日美国当周准备金创一纪录金库18662万磅的 减少	华卓刚	陈莉	3110	142
567052387495		2017-12-20 00:00:00	1	中国证券报	52	黄金需求多支撑沪金 企稳	投资者更倾向持有美元资产加息预期,上周金价在美联储 减少	姜尚德	杨斌	3130	7
567093278115		2017-12-20 00:00:00	99	金融界	51	美国股市中创市场波动 风险	惠康 比特币从长期来看,对比特币投资需求并未因美联储的 减少			3130	142
567090716067		2017-12-20 00:00:00	99	生财社	51	中安基金:基金市场多事难料持 谨慎	生财社12月20日讯【市场分析】编辑陈文豪 减少	毕宏刚		3130	7
567090734931		2017-12-20 00:00:00	99	生财社	51	国联基金:创业板在沪市企稳步 企稳	生财社12月20日讯【市场】外汇基金市场仍偏于 减少	国联基金		3130	7
56706813256		2017-12-20 00:00:00	146	FX168	51	世界黄金协会:黄金作为避险资产 中坚	FX168财经社(香港讯) 世界黄金协会投资研究主管指出			3130	7
56707349891		2017-12-20 00:00:00	99	中国证券报	51	黄金价格不温不火,金市仍遭美元走势牵制 平淡	对于全球黄金生产商而言,美国有两大种,一种黄金的供给 减少			3130	142
567071589105		2017-12-20 00:00:00	146	FX168	51	【国信黄金收盘】黄金价格进一步 三跌 黄金价格不断回落整	FX168财经社(香港讯) 国信黄金收盘(12月19日) 减少			3130	7
56706212687		2017-12-20 00:00:00	146	FX168	51	技术分析:黄金市场进一步反弹 风险 美联储12月30组力 区	FX168财经社(香港讯) FX168Tech 减少			3130	7
56706522700		2017-12-20 00:00:00	146	FX168	51	黄金日内交易分析:技术因素波动引起 起跌 预期下跌	FX168财经社(香港讯) 资讯网Economics 减少			3130	7
56706361798		2017-12-20 00:00:00	1	中国证券报	51	博时基金王: 黄金后市看好在 现在	上周黄金市场面临美联储加息预期升水一美元联储加息和 减少		蔡文胜	3130	7
567044180653		2017-12-20 00:00:00	38	每日经济新闻	51	朱晶:比特币一年涨幅20%吸引投资者吃 肉 仍应警惕“熊 杀	在回顾过去的2017年,如果看到全球投资到加密货币的 资产		朱晶	3130	7
567052235197		2017-12-20 00:00:00	1	中国证券报	51	陕西自贸区“产业招商”举措 上市	华章智库指出12月21日双所 上市 ,这对产融结合 全			3110	142
567052342010		2017-12-20 00:00:00	1	中国证券报	51	产融结合: 产融结合存在 风险	12月21日以来,产融结合持续了一个月,融 企稳		张静	3130	142
567052279182		2017-12-20 00:00:00	1	中国证券报	51	海南自贸中试: “保税+期货”完成 理赔	12月15日下午,海南自贸中试在海南中试保税大 减少		马南	3110	142
567052308928		2017-12-20 00:00:00	1	中国证券报	51	大商所:期货合约全面 打	2017年,大商所期货结算量创历史新高,与银行 为		马南	2345	142
56705209239		2017-12-20 00:00:00	1	中国证券报	51	天然气:国内油价创 新高 农产品价格有 企稳 几何	随着“国际粮,农产品市场进入季,但今年的农产品市场出 减少		张静	3110	142
567069894685		2017-12-20 00:00:00	19	中国证券报	50	国信期货收盘: 10年期国债主力合约 涨 0.03%	中国证券报讯: 12月20日,国信期货收盘上 涨 ,10年期 减少			3153	142
567099151678		2017-12-20 00:00:00	14	和讯	50	有色:沪钨12月19日收盘 涨 0.02% 螺纹钢 大	和讯财经讯: 周二(12月20日)商品市场午后 震荡 不锈钢 多			3100	142
567068833252		2017-12-20 00:00:00	158	证券时报网	50	国信期货收盘: 10年期国债主力合约 涨 0.03%	周二(12月20日),多			3153	142
567097820519		2017-12-20 00:00:00	158	证券时报网	50	国信期货收盘: 10年期国债主力合约 涨 0.03%	证券时报网12月20日讯 周二(12月20日),多			3100	142
567093214714		2017-12-20 00:00:00	99	金融界	50	央行黄金增持持续 升温	回顾2017年“黄金货币”运动的遗产,将在未来长期 多			3130	7
567093252860		2017-12-20 00:00:00	99	金融界	50	央行黄金增持持续 升温					

数据来源：聚源数据，中信建投证券

2.2 数据清洗

在汇总的新闻数据库中，不同的财经媒体偶尔会发布相同的新闻信息，为避免后续查询到相同的内容，首先需要对文本进行去重处理。本文采用SimHash算法对文本进行去重。

SimHash是google于2007年发布的一篇论文《Detecting Near-duplicates for web crawling》中提出的算法，被应用在Google搜索引擎网页去重的工作之中。该算法的核心思想是将高维的特征向量映射到一个低维的二进制签名中，通过比较两个文本的二进制签名来确定它们的相似性。

算法的具体流程为：

- 1.分词与特征提取：首先对文本进行分词，提取关键词作为特征向量。
- 2.特征加权：对提取出的关键词进行加权处理，常用的权重计算方法包括词频（TF）和逆文档频率（IDF）。
- 3.哈希降维：使用哈希函数将每个特征转换为二进制的哈希值，通常为固定位数，如64位。
- 4.加权向量合并：将所有特征的加权哈希值合并成一个向量，并进行加权求和。
- 5.降维得到签名：对合并后的向量进行降维处理，根据每个维度的和是否大于0来确定最终的二进制签名，大于0则为1，否则为0。
- 6.相似度判断：通过比较两个文本的SimHash签名的海明距离（即不同位数的个数）来判断它们的相似度。海明距离越小，文本越相似。

以以下三个新闻文本为例，分别计算三个文本间的海明距离，对于不同样本，如果海明距离小于3，则认为是重复样本。

S1: 美团抢占香港市场!KeeTa来了

S2: 打工人利好!上海租赁住房又有新动作!

S3: 神舟十六号计划近日择机实施发射 船箭组合体转运至发射区

表 1:新闻文本海明距离


	S1	S2	S3
S1	0	30	33
S2	30	0	29
S3	33	29	0

资料来源：聚源数据，中信建投证券

其他的清洗步骤包括：去除特殊符号，剔除太长或者太短的新闻文本，剔除非专业新闻媒体信息等。最终得到了44万条不重复的新闻文本数据，总文本长度约为4.3亿字段。

虽然目前大模型对于长上下文的推理效率不断提高，但是依然难以一次性处理上述上亿长度的文本数据，如果采用重新预训练大模型或者微调模型的方式，训练成本会急剧增加。对于具体方案的采用可以参考下图：

图 2:大模型方案决策流程



数据来源: Large Language Models in Finance: A Survey, 中信建投证券

在综合效率和成本考量之后，本文采用RAG框架分析新闻文本数据。检索增强生成（Retrieval-Augmented Generation，简称RAG）是一种结合了信息检索和文本生成的技术，旨在提升大型语言模型（Large Language Models，简称LLMs）的性能和输出的准确性。RAG通过从外部知识库检索相关信息，辅助LLMs生成更准确、更丰富的回答，同时减少模型幻觉的问题。

RAG的核心在于两个组件：信息检索（Retrieve）和文本生成（Generate）。在接收到用户的查询后，RAG首先使用检索组件在大型的知识库或文档集合中搜索与问题相关的信息。这一过程类似于人在图书馆中查找相关书籍以回答某个问题。检索到的信息随后被用作文本生成组件的输入，该组件负责根据检索到的信息生成一个连贯、准确的回答。




Fig. 1. A generic RAG architecture. The users' queries, which may be different modality, serve as input to both the retriever and the generator. The retriever searches for relevant data sources in storage, while the generator interacts with the retrieval results and ultimately produces results of various modalities.

数据来源: Retrieval-Augmented Generation for AI-Generated Content: A Survey, 中信建投证券

RAG的主要优势在于其能够提高答案的准确性和相关性。通过引用外部知识库中的信息，RAG可以提供更准确的回答，增加用户信任。此外，RAG便于知识更新和引入特定领域知识，有效解决了知识更新的问题。RAG还可以根据特定领域进行定制，为特定领域提供知识支持。


在检索增强生成（Retrieval-Augmented Generation, RAG）框架的领域内，LangChain和LlamaIndex是两个广受推崇的技术解决方案，它们均旨在为大型语言模型（Large Language Models, LLMs）的应用开发提供支持。这两个框架均装备了一系列高级组件和工具，用以增强开发者构建复杂应用的能力。

在本研究中，我们将重点探讨利用LangChain框架中的组件来开发一个本地化的RAG系统。该系统旨在结合LangChain的灵活性和高效性，以实现LLMs的优化利用，并提升其在财经新闻分析场景中的性能。通过精心选择和集成LangChain所提供的功能模块，我们期望该本地化RAG系统能够更好地适应特定的数据处理需求，同时保持与现有技术的兼容性和扩展性。

3.1 信息检索-向量数据库

为了便于后续检索，首先需要将新闻文本数据存储于向量数据库。向量数据库专门设计用于存储和处理向量数据，这些向量通常是由文本、图像、音频和视频等非结构化数据通过机器学习模型、词嵌入或特征提取技术转换而来。与传统数据库不同，向量数据库的核心优势在于其能够高效地进行高维向量相似性检索，非常适用于机器学习和人工智能应用中，如图片识别、自然语言处理、推荐系统等。

在传统的字符串匹配方法中，检索过程依赖于对文本内容的精确匹配，这在处理大量数据时往往会遇到性能瓶颈，并且难以准确捕捉文本的语义信息。然而，向量空间模型通过将文本转换为数值向量，不仅能够有效地降低计算复杂度，提高检索效率，而且还能够通过计算向量之间的相似度来实现基于语义的检索。



数据来源: Langchain, 中信建投证券


公众号·中信建投金工及基金研究团队

向量数据库的主要特点包括高度可扩展性、高效的相似性搜索能力和对高维数据的支持。它们使用称为“近似最近邻”(Approximate Nearest Neighbor, ANN)搜索的搜索技术，这包括哈希和基于图的搜索等方法，以实现快速准确的相似性检索。

目前市面上存在多种向量数据库产品和开源项目，例如Chroma、Pinecone、Weaviate、Faiss和Qdrant等，它们各自提供了不同的功能和特性，以满足不同应用场景的需求。随着人工智能和机器学习技术的不断进步，向量数据库在数据检索、处理和分析方面的作用将变得越来越重要，它们有望在各个领域提供更复杂、更高效、更个性化的解决方案。

本文采用Milvus数据库，Milvus 是一款开源的向量数据库，专为海量特征向量的相似性搜索而设计。它基于异构众核计算框架，能够在有限的计算资源下实现高效能和低成本的搜索，支持十亿级别的向量搜索仅需毫秒级响应。

图 5: milvus 数据库



数据来源: milvus, 中信建投证券

公众号·中信建投金工及基金研究团队

数据导入流程主要包括以下几个步骤：

3.1.1 文本切分

首先加载原始数据，Langchain提供了一系列数据加载工具，包括WEB、PDF、JSON、CSV等各种结构和非结构化数据。我们将清洗之后的新闻文本数据加载。

加载完成后需要对文本进行切分，切分的主要目的是为了提高检索效率，增强检索的准确性，为后续大模型提供输入，提高大模型对于信息的理解。常用的文本切分方式包括句子切分、词语切分、短语切分、基于规则切分、基于模型切分等。Langchain的TextSplitter中提供了许多函数用于切分数据，本文采用默认的RecursiveCharacterTextSplitter对新闻数据进行切分。RecursiveCharacterTextSplitter（递归字符文本分割器），会通过不同的符号递归地分割文档，同时兼顾文本的长度以及重叠部分的长度。默认使用“\n\n”, “\n”, “ ”, “ ”这四个特殊字符进行切分。

我们将子文本长度设为500，最终原始4.3亿字段的文本切分为了94万个子文本。切分后的子文本具体样例如下所示，可以看出，经过切分之后的子文本依然保持了较好的结构以及完整的信息。

图 6:子文本样例

新型工业化发展潜力巨大。以工业互联网为例，目前已应用于 45 个国民经济大类，2022 年产业规模超万亿元。从实践来看，以工业互联网赋能产业发展，有利于推动实体经济实现数字化转型，并通过生产方式、经营模式的重塑，使企业实现降本、提质、增效，进一步激活实体经济发展活力。

海尔集团从 2007 年开始探索工业互联网，于 2017 年正式推出卡奥斯工业互联网平台。现在，卡奥斯工业互联网平台已经链接企业 90 万家，服务企业 8 万多家。

通过一线走访调研，周云杰发现我国工业数据的应用仍处于中低端水平，自主可控能力不强，主要存在三个方面的问题：一是“大而不强”，数据很多，但被有效挖掘和利用的比例不高。二是“全而不优”，在资源配置与系统实现价值增值方面，多数平台的数据分析处理能力还有待提高。三是“广而不通”，从平台间数据互联互通的角度看，数据壁垒林立，平台间数据流通阻力较大。

数据来源：聚源数据，中信建投证券

3.1.2 文本嵌入

文本嵌入（Embedding）是指将文本映射为嵌入向量的过程。通过嵌入向量，能够完成多种自然语言任务，包括语义相似度，文本聚类，文本分类，信息检索，问答系统，自然语言理解，翻译等。

文本嵌入模型一般采用预训练模型，也可根据实际任务进行微调。常用的中文预训练embedding模型有OpenAI的text-embedding-ada-002，MOKA的m3e，阿里的gte，智源的bge等，各模型的表现可参考Huggingface的MTEB Chinese leaderboard。本文采用目前中文模型中表现最好acge_text_embedding模型，模型来自于合合信息技术团队，模型输出维度为1792维。

图 7: MTEB Chinese leaderboard

Rank	Model	Model Size (Million Parameters)	Memory Usage (GB, fp32)	Embedding Dimensions	Max Tokens	Average (35 datasets)	Classification Average (9 datasets)	Clustering Average (4 datasets)	Pair Classification Average (2 datasets)	Reranking Average (4 datasets)
1	acge_text_embedding	326	1.21	1792	1024	69.07	72.75	58.7	87.84	67.98
2	OpenSearch-text-hybrid			1792	512	68.71	71.74	53.75	88.1	68.27
3	stella-mrl-large-zh-v3.5-1792	326	1.21	1792	512	68.55	71.56	54.32	88.08	68.45
4	stella-large-zh-v3-1792d	325	1.21	1792	512	68.48	71.5	53.9	88.1	68.26
5	IYun-large-zh	326	1.21	1024	1024	68.44	71.68	54.4	86.7	68.66
6	Baichuan-text-embedding			1024	512	68.34	72.84	56.88	82.32	69.67
7	stella-base-zh-v3-1792d	102	0.38	1792	1024	67.96	71.12	53.3	87.93	67.84
8	Dmeta-embedding-zh	103	0.38	768	1024	67.51	70	50.96	88.92	67.17
9	xiaobu-embedding	326	1.21	1024	512	67.28	71.2	54.62	85.3	67.34
10	alime-embedding-large-zh	326	1.21	1024	512	67.17	71.35	54	84.34	67.61

数据来源：Huggingface, MTEB: Massive Text Embedding Benchmark, 中信建投证券

3.1.2 向量数据库

将94万个子文本进行Embedding,最终得到94万个1792维的向量。为了便于向量检索以及更新维护，我们将这些向量存入向量数据库Milvus，同时建立索引。

图 8:Milvus 数据库

id	content	embedding
202301100572	刘永好提出了三点期望，一是开放产业链场景...	[0.939434289932251,-0.39178070425967244,0.70019221305...
202301171441	中科智云CEO魏宏峰表示：“本轮融资获得国...	[0.4511127471923828,-0.34871649742126465,0.0341370254...
202301301015	中联重科塔机也尽显冠军风采，近200台车辆...	[-0.577038288164551,-0.6579735279083252,0.1708573251...
202302140958	发展目标方面，无锡明确，到2025年，4个地...	[-0.47468364238739014,-1.1363041400909424,0.643926739...
202302140959	据介绍，接下来，无锡将从聚力“点上突破”、...	[-0.39946335554122925,-1.2588121891021729,0.755948603...
202302180179	“腾讯与英雄联盟创始团队有着超过10年的合...	[0.15596646070480347,-0.3445884585380554,0.6469076871...
202302282390	国务院发展研究中心研究员龙海波认为，近年...	[-0.02081798017024994,-0.9449114799499512,1.389866590...
202303022719	49.40.4 7月/202249-1.2 6月/2022 50.20.6 ...	[0.13812440633773804,-0.07461628317832947,-0.61001300...
202303022721	第三、需要充足的资金资源支撑。5G专网需要...	[-0.08412420749664307,-0.7554672360420227,0.392598509...
202303030506	《“十四五”机器人产业发展规划》指明了行业...	[0.04108317196369171,-0.9005208015441895,0.8228790760...
202303070249	李毛还建议，制定科技创新扶持保障条款，进...	[-0.15385347604751587,-1.3535751104354858,0.644967615...
202303070250	林孝发表示，我国“5G+工业互联网”蓬勃发展...	[-0.38023823499679565,-1.5089430809020996,0.531789422...
202303281500	达闼机器人研发总监梁翊则表示，要不计成...	[-0.33609819412231445,-0.8049595355987549,0.270133137...
202303300386	王江平表示，中国制造业现在正处于从内部资...	[0.05631847679615021,-0.6416276097297668,0.4433860347...
202303311410	“数字经济下半场是和实体经济相融合的，特别...	[0.2195495218038559,-0.9360710382461548,1.01595330238...
202304140654	还是以卫浴行业的九牧为例，在数智化加持下...	[-0.02033466100692749,-0.49046623706817627,0.57840633...

数据来源：聚源数据，中信建投证券

在进行文本数据分析的过程中，内积计算作为一种有效的数学工具，能够用于量化文本向量之间的相似性，从而实现相关新闻文本数据的精确提取。以内积为基础的相似度评估方法，通过计算两个向量的点积并将其与各自模长的乘积进行比较。

以2024年3月29日关于贵州茅台的新闻报道为例，在预先构建的向量数据库中高效地检索出与该主题相关的新闻数据。

图 9:新闻检索


id	score	content
202403291387	250.16969299316406	公司酒标业务主要产品为茅台(1835)、贵州茅台酒(吴非免年)、贵州茅台王子酒(吴非免年)、茅台醇系列酒、习酒系列酒、舍得系列酒、国台系列酒等产品品牌。2023年，公司酒标整体订单量较
202403291420	237.42054748535156	会上，茅台集团党委副书记、工会主席、监事会主席游亚林总结了推动茅台发展的三点精髓：第一品质是茅台的制胜法宝，要确保每一瓶酒品质如一，时间的沉淀、空间的孕育、工法的坚守赋
202403292301	200.41099548339844	置巴葡萄酒集团方面对《证券日报》记者称，接下来，集团将开始逐步扩大在中国的高端奢华系列中澳大利亚葡萄酒的产品布局，并将增加对本地的销售和市场营销的资源投入。与此同时，公
202403291421	196.8500518798828	财经作家、《茅台传》作者吴晓波在主题演讲环节，分享了他创作《茅台传》过程中的观察和思考。吴晓波表示，企业和人一样，需要在快与慢之间做出选择。而茅台集团与自己过去关注的
202403291778	182.07830815466875	2024-03-29发布：《聚力解难题让“多彩”变“多产”上交所会同多部门走进贵州上市公司》自国务院召开部署走访上市公司工作、推动上市公司高质量发展全国视频会议以来，沪市公司的走访调
202403292204	178.45327758789062	为进一步优化供应网络布局，2023年公司旗下库尔斯酒庄灌装生产线竣工，该酒庄总产能将达每年15万升。万州酒庄在2023年末复产，有效支持了市场需求的增长。佛山酒庄建设进展顺利，
202403292611	172.80343627929688	在2024年3月21日发布年度新品“青韵奖”中，公司旗下重庆精酿白啤、凤花雪月桃花瑶低醇啤酒和布鲁克林皮尔森均获得2023年度“青韵奖”，体现了业内对重啤股份产品的高度认可。2024年初，
202403292310	168.6273193359375	佛山酒庄建设进展顺利，预计在2024年第二季度投产，年产能将达到50万升，年产值约20亿元，在供应广东市场的同时，辐射华南周边市场，大幅降低物流运输费用，更好满足粤港澳大湾区

数据来源：聚源数据，中信建投证券

3.2 文本生成

通过将用户的查询问题与检索得到的相关信息进行有效整合构建出提示词（prompt），我们可以为大型语言模型提供明确且有针对性的输入。这种方法引导模型进行更为深入的分析、全面总结以及逻辑推理，从而显著降低了模型产生错误或偏差（即“幻视”）的可能性，并有效提升了模型在处理复杂问题时的表现和准确性。

图 10:文本生成



数据来源: Langchain, 中信建投证券

3.2.1 大模型部署

相较于商业性质的人工智能模型，开源大型语言模型展现出了更高的灵活性和可定制性。在遵守相应的许可协议的前提下，开发者和研究者可以对开源模型进行深入的再加工和优化，以适应特定的应用场景和需求。

这种灵活性使得开源大模型能够被有效地整合进各种下游任务中，例如自然语言处理、机器翻译、情感分析等。通过对模型结构、训练数据集或优化算法的调整，开发者可以根据具体任务的特点和挑战，提升模型的性能和准确度。

随着模型参数的增加，以及新技术的提出，大模型的表现不断提高，在Huggingface的leaderboard中，大模型的表现不断逼近甚至超越人类水平。

图 11:大模型平均表现变化




数据来源:

https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard

, 中信建投证券

图 12:子任务得分最高的大模型表现变化



数据来源:

https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard

, 中信建投证券

目前在 leaderboard 上排名靠前的的大模型如下图所示:

图 13:Open LLM Leaderboard

Model	Average	ARC	HellaSwag	MMLU	TruthfulQA	Winogrande	GSM8K
gpt-4o	81.22	79.78	91.15	77.95	74.5	87.85	76.12
Qwen2.5-72B-Instruct	81	78.67	89.77	78.22	75.18	87.53	76.65
Qwen2.5-72B-Instruct	80.98	78.58	89.74	78.27	75.89	87.37	76.8
SE-FoundatioNemo-72B-v0.11	80.81	76.79	89.62	77.2	79.62	84.06	78.77
SE-FoundatioNemo-72B-v0.12	80.79	76.19	89.44	77.67	77.62	84.53	79.3
SE-FoundatioNemo-72B-v0.12	80.72	76.19	89.46	77.17	77.78	84.45	79.23
Alibaba/Qwen2.5-72B-v0.1	80.48	76.82	89.27	77.15	76.67	85.88	78.7
Meta/Llama-3.1-8B-Instruct	79.3	73.89	88.16	77.4	72.69	86.83	77.63
moonshot/K1.7B-Instruct	78.55	78.82	85.96	77.13	74.71	84.86	78.62
Qwen2.5-72B-Instruct	77.91	74.06	86.74	76.65	72.24	83.35	74.45
Qwen2.5-72B-Instruct	77.74	77.47	91.88	68.1	79.17	87.45	62.4
Qwen2.5-72B-Instruct	77.52	74.06	86.67	76.69	73.32	83.43	72.93

数据来源: https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard, 中信建投证券


为了促进大语言模型（LLM）的本地化部署，本研究选用了ollama框架作为技术支撑。ollama框架是一个支持跨平台的开源解决方案，专门设计用于通过Docker容器技术进行LLMs的部署与维护，

从而显著降低了部署大型语言模型的技术门槛。该框架内置了一系列广泛使用的LLM模型，如Llama2、Gemma、Mistral、Mixtral、Qwen及Yi等，此外，ollama还支持通过Modelfile文件来管理和执行本地下载的LLM模型，为用户提供了更高的灵活性和自主性。

其中Mixtral模型是由Mistral AI公司开发的一种先进的人工智能模型，该模型的设计旨在提高处理效率和准确度，同时降低计算成本。Mixtral-8x7B是基于Mistral 7B的MoE（Mixture of Experts）模型，它通过引入MoE结构来进一步提升性能。MoE结构的核心思想是将一个大型网络分解为多个专家（Experts），每个专家负责处理特定类型的任务或数据。在实际应用中，根据输入数据的特性，通过一个门控机制（Gate）来选择性激活相应的专家进行计算，这样可以提高模型的专注度和效率。

结合各种前端框架，ollama框架使得调用和集成各类大型语言模型变得异常简便。通过这种方式，用户可以轻松构建出功能强大的自然语言处理应用。

图 14: OLLAMA + Open WebUI 前端页面



数据来源：OLLAMA, 中信建投证券

公众号 · 中信建投金工及基金研究团队

open-webui结合ollama也可以实现简单的RAG功能，用户可以通过前台或者后台上传相关文档，交给LLM模型进行分析。

同时，本地化部署大模型后可以支持API调用，兼容OpenAI的函数接口，可以将API和插件和软件相结合，提供更加丰富的使用场景。

图 15:手机端调用 OLLAMA API



数据来源: OLLAMA, 中信建投证券

公众号 · 中信建投金工及基金研究团队

3.2.2 文本生成

在部署大型语言模型（LLM）之后，系统将能够依据用户提出的问题，并结合向量数据库中存储的相关信息，生成精准的提示词。随后，这些提示词将被用于引导LLM生成相应的答案。

为了确保模型管理的高效性和便捷性，我们使用Langchain提供的LLMs接口。Langchain的接口不仅支持对本地模型的便捷管理，而且通过其强大的接口功能，我们同样能够轻松地调用包括GPT、Moonshot等在内的商业大模型。这种灵活性极大地丰富了我们对于不同模型资源的访问能力，同时也为后续的模式集成和应用开发提供了坚实的基础。

以科技行业2024年3月29日新闻为例，要求LLM将查询得到的相关新闻进行总结，得到以下结果：

- 1.科技金融是未来金融发展的重要方向，建设银行在深圳成立了科技金融创新中心，将加快推进科技金融业务的创新和发展。
- 2.5G-A是5G向6G发展的关键阶段，具备更高速率、更大连接、更低时延等特点。运营商作为5G-A策源地将协同产业链，不断引领关键技术导入并打造标杆应用，5G-A商用化落地或增厚新兴业务收入。无线主设备、天线、射频等设备厂商也将迎来新成长空间。
- 3.随着AI在各领域的应用延伸，手机、服务器、PC中DRAM和NAND单机平均搭载容量均有成长，三星、SK海力士及美光全面调升上半年稼动率。受益于价格的持续回暖，以及HBM和DDR5等高端产品的需求增长，存储芯片板块上下游公司有望充分受益。
- 4.科东软件与英特尔在工业AI机器人领域展示了双方的合作成果，这也是对未来工业生产智能化的一次大胆预见。随着汽车走向端到端智能驾驶，行业最终向AI定义汽车的方向演进，单车也更接近一个通用AgentAI，随着未来世界模型的接入将成为通用机器人落地的首个场景。

可以看出，文本中虽然不一定包含有科技相关的文本，但是通过语义检索以及分析，LLM依然成功的总结出了当日科技相关的新闻。

四、RAG用于市场分析

传统投资领域的专业人士每日肩负着分析庞杂新闻资讯的重任，旨在从中甄别出对市场趋势具有重大影响的信息。这一过程不仅要求投资者具备深厚的专业知识和丰富的实践经验，还需要投入大量的时间和精力进行细致的研读与分析。

通过利用大型语言模型（LLM）的先进数据分析和推理能力，结合本地化的检索增强生成（RAG）系统，我们能够高效地执行这一任务。投资者可以根据个性化需求，指导LLM对新闻资讯进行深度分析，并生成相应的分析结果。在本研究中，我们运用LLM对市场趋势进行预测，并制定相应的市场择时和行业轮动策略。

为确保所分析的信息的新颖性，避免使用已用于模型训练的数据，本研究选取了2023年之后的新闻数据进行周频市场预测。

在使用LLM进行预测时，我们构建了一个模拟资深分析师的代理（Agent），该代理专门负责分析新闻数据和市场状况，并预测市场的未来走势，同时按照既定格式输出分析结果。为减少模型输出的不确定性，我们将温度参数（temperature）设为0，同时设置top_k为1，确保每次预测的唯一性。


4.1 LLM择时

在进行市场未来趋势预测的过程中，我们向代理模型提供了包含过去一周内市场关键新闻资讯及历史表现数据的详尽信息集，以便模型能够基于这些信息生成对未来一周市场走势的预测分析。

在对不同模型的预测能力进行评估时，我们选择了包括qwen:14b、Mixtral 8x7B、GPT-3.5-Turbo以及GPT-4-Turbo-Preview在内的多种模型进行测试。然而，在实际应用中，Gemma、Llama2等其他模型未能按照预定要求输出有效结果，导致无法进行有效的比较分析。

对于上证综指未来一周涨跌幅进行预测，按照预测信号进行多空择时，最终策略的费前净值如下：


图 16: LLM 上证综指多空择时净值



数据来源：聚源数据，中信建投证券


公众号：中信建投金工及基金研究团队

图 17: LLM 上证综指多头择时净值



数据来源：聚源数据，中信建投证券

图 18: LLM 上证综指空头择时净值



数据来源：聚源数据，中信建投证券

公众号·中信建投金工及基金研究团队

表 2: LLM 多空择时策略表现

	多空年化 收益	基准年化 收益	IR	最大回撤	基准最大 回撤	多头年化 收益	空头年化 收益	准确率
qwen:14b	-5.38%	0.38%	-0.41	17.63%	16.33%	-2.25%	-3.23%	52.46%
mixtral	13.49%	0.38%	1.03	9.32%	16.33%	7.33%	5.64%	60.66%
gpt3.5	4.08%	0.38%	0.31	11.96%	16.33%	2.31%	1.72%	59.02%
gpt4	-3.92%	0.38%	-0.30	21.23%	16.33%	-1.77%	-2.20%	54.10%

资料来源：聚源数据，中信建投证券


从各模型对比可以看出，表现最好的是 mixtral，其次是 gpt3.5, gpt4 以及 qwen:14b 表现较为一般。其中 mixtral 的 alpha 达到 13%，择时准确率为 60.66%。

公众号·中信建投金工及基金研究团队

4.2 LLM行业轮动


同样，我们也可以结合新闻数据以及市场状态，要求LLM输出推荐行业。具体步骤为：首先在数据库检索过去一周重要的市场新闻。其次将新闻信息和过去一周市场表现结合在一起，要求LLM根据这些信息预测未来一周表现最好的五个行业，根据预测信号构建等权组合，周频进行调仓，采用mixtral 8*7b模型，基准为30个行业等权组合，最终策略费前表现如下：

图 19: LLM 行业推荐



数据来源：聚源数据，中信建投证券

图 20: LLM 行业轮动策略净值



数据来源：聚源数据，中信建投证券

公众号 · 中信建投金工及基金研究团队

表 3: LLM 行业轮动策略表现

	年化收益	最大回撤	年化波动率	IR
mixtral	1.81%	33.33%	0.22	0.08
benchmark	-6.74%	25.42%	0.16	-0.42

资料来源：聚源数据，中信建投证券


相较于基准，LLM 行业轮动策略的 alpha 为 8.5%，明显超越基准表现

公众号 · 中信建投金工及基金研究团队

4.3 LLM行业轮动+择时

将LLM行业择时与LLM行业轮动进行叠加，构建多头行业轮动择时组合，策略的费前表现如下：

图 21: LLM 行业轮动+择时策略净值



数据来源：聚源数据，中信建投证券

公众号 · 中信建投金工及基金研究团队

表 4: LLM 行业轮动+择时策略表现

	年化收益	最大回撤	年化波动率
mixtral	16.20%	7.51%	0.12
benchmark	-6.74%	25.42%	0.16

资料来源：聚源数据，中信建投证券

LLM 行业轮动+择时策略，相较于基准年化 alpha 达到了 22.9%，最大回撤也有明显改善。

公众号 · 中信建投金工及基金研究团队

五、总结

本研究通过融合新闻数据与先进的大型语言模型，成功构建了一个本地化的RAG（Retrieval-Augmented Generation）系统。该系统充分利用了大型语言模型在文本总结、分析和推理方面的强大能力，并结合市场新闻和状态信息，以实现对一系列复杂下游任务的有效处理。在本研究中，我们依据大型语言模型生成的预测信号，进一步设计并实施了三种策略：市场择时策略、行业轮动策略以及综合行业轮动与市场择时的复合策略。通过对这些策略的实证分析，我们发现RAG系统在实际应用中展现出了卓越的性能。

风险分析

本报告中所有数据结果是基于历史统计结果的展示，未来有可能发生风格切换导致因子失效的风险。模型运行存在一定的随机性，初始化随机数种子会对结果产生影响，单次运行结果可能会有一定偏差。历史数据的区间选择会对结果产生一定的影响。模型参数的不同会影响最终结果。模型对计算资源要求较高，运算量不足会导致结果存在一定的欠拟合风险。本文所有模型结果均来自历史数据，模型存在统计误差，不保证模型未来的有效性，对投资不构成任何建议。

分析师介绍

姚紫薇，金融工程及基金研究首席分析师。上海财经大学管理学硕士，厦门大学统计学学士，在基金研究、资产配置、产品设计、财富管理等领域均有长期深入研究。曾担任招商证券基金评价业务负责人，多次获得“新财富”金融工程方向前三（团队核心成员）。

王超，南京大学粒子物理博士，曾担任基金公司研究员，券商研究员，有丰富的研究和投资经验，2021年加入中信建投证券研究所，主要负责量化多因子选股。

证券研究报告名称：《“逐鹿”Alpha专题报告（二十）——基于数亿新闻上下文的本地RAG系统用于市场择时及行业轮动》

对外发布时间：2024年4月10日

报告发布机构 中信建投证券股份有限公司

本报告分析师：

姚紫薇 SAC编号：S1440524040001

王超 SAC编号：S1440522120002

免责声明：

【各团队公众号】

本订阅号（微信号：中信建投金工及基金研究团队）为中信建投证券股份有限公司（下称“中信建投”）研究发展部金融工程与基金研究团队运营的唯一订阅号。本订阅号所载内容仅面向符合《证券期货投资者适当性管理办法》规定的机构类专业投资者。中信建投不因任何订阅或接收本订阅号内容的行为而将订阅人视为中信建投的客户。本订阅号不是中信建投研究报告的发布平台，所载内容均来自于中信建投已正式发布的研究报告或对报告进行的跟踪与解读，订阅者若使用所载资料，有可能会因缺乏对完整报告的了解而对其中关键假设、评级、目标价等内容产生误解。提请订阅者参阅中信建投已发布的完整证券研究报告，仔细阅读其所附各项声明、信息披露事项及风险提示，关注相关的分析、预测能够成立的关键假设条件，关注投资评级和证券目标价格的预测时间周期，并准确理解投资评级的含义。

中信建投对本订阅号所载资料的准确性、可靠性、时效性及完整性不作任何明示或暗示的保证。本订阅号中资料、意见等仅代表来源证券研究报告发布当日的判断，相关研究观点可依据中信建投后续发布的证券研究报告在不发布通知的情形下作出更改。中信建投的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本订阅号中资料意见不一致的市场评论和/或观点。

本订阅号发布的内容并非投资决策服务，在任何情形下都不构成对接收本订阅号内容受众的任何投资建议。订阅者应当充分了解各类投资风险，根据自身情况自主做出投资决策并自行承担投资风险。订阅者根据本订阅号内容做出的任何决策与中信建投或相关作者无关。

本订阅号发布的内容仅为中信建投所有。未经中信建投事先书面许可，任何机构和/或个人不得以任何形式转发、翻版、复制、发布或引用本订阅号发布的全部或部分内容，亦不得从未经中信建投书面授权的任何机构、个人或其运营的媒体平台接收、翻版、复制或引用本订阅号发布的全部或部分内容。版权所有，违者必究。

上一篇

【中信建投金工及基金研究】追寻优秀基因 | 如何构建基金标签矩阵

下一篇

【中信建投金工及基金研究】基于XAI的循环神经网络选股模型可解释性探究