

“逐鹿”Alpha专题报告（二十三）——融合LLMs进化的基本面因子挖掘统一框架

中信建投金工及基金研究团队 2024年11月07日 07:45 上海

【重要提示】：通过本订阅号发布的观点和信息仅供中信建投证券股份有限公司（下称“中信建投”）客户中符合《证券期货投资者适当性管理办法》规定的机构类专业投资者参考。因本订阅号暂时无法设置访问限制，若您并非中信建投客户中的机构类专业投资者，为控制投资风险，请您取消关注，请勿订阅、接收或使用本订阅号中的任何信息。对由此给您造成的不便表示诚挚歉意，感谢您的理解与配合！



证券研究报告·金融工程专题报告

“逐鹿”Alpha专题报告（二十三）：融合LLMs进化的基本面因子挖掘统一框架

分析师：姚紫薇

yaoziwei@csc.com.cn

SAC编号：S144052404000

分析师：王超

wangchaodcq@csc.com.cn

SAC 编号：S1440522120002

发布日期：2024年11月6日

公众号·中信建投金工及基金研究团队

本报告由中信建投证券股份有限公司在中华人民共和国（仅为本报告目的，不包括香港、澳门、台湾）提供。在遵守适用的法律法规情况下，本报告亦可能由中信建投（国际）证券有限公司在香港提供。请务必阅读正文之后的免责声明和声明。

提纲

01

基本面因子挖掘框架更新

02

LLMs 进化结构

03

总结

公众号·中信建投金工及基金研究团队

核心观点

本文深入探讨了如何通过融合大型语言模型（LLMs）来进化和优化基本面因子挖掘的统一框架。报告首先回顾了基本面因子挖掘的三种主要范式：传统的手动挖掘、基于算法的自动挖掘，以及最新的Human-AI交互算法。特别强调了Human-AI交互算法的优势，即结合了LLMs的能力，按照人类的指导进行因子挖掘，以生成大量可解释的因子。

本文详细介绍了基本面因子挖掘的统一框架，包括因子生成、计算、验证和筛选的全过程。在因子生成阶段，采用了随机法、枚举法和领域知识法来构造因子结构，并通过限制复杂度和量纲的合法性来确保因子的简洁性和可解释性。因子计算阶段，报告提出了一个两层结构，自动处理因子的量纲、频率和公告期等问题，同时介绍了多种算子，包括元素、时序和横截面算子，以及它们的量纲规则。

为了提高因子计算的效率，本文提出了使用Cython和流式计算技术的解决方案，显著减少了计算时间。在因子进化阶段，结合了遗传规划算法（GP）和LLMs，通过大模型分析因子的含义和规律，生成改进后的因子。报告还提供了LLMs进化因子的示例，展示了如何根据给定的IC指标和历史因子输出新的改进因子。

最后，通过模型回测对比，Factor Zoo的因子展示除了更加稳定的收益，将Factor Zoo因子与OPENFE因子融合后，收益及稳定性均有所提升。



公众号 · 中信建投金工及基金研究团队

PART 1

基本面因子挖掘框架更新

公众号 · 中信建投金工及基金研究团队



因子挖掘三种范式




Figure 1: Evolution of alpha mining techniques.


P1: 手动挖掘因子，依靠研究员主观经验，效率低且成本较高

P2: 算法挖掘，利用GP,RL等算法自动大量挖掘因子，因子可解释性较差

P3: Human-AI交互算法，利用LLMs分析因子，按照人类要求进行因子挖掘，自动批量生成可解释的因子

公众号 · 中信建投金工及基金研究团队





并非直接使用LLMs生成因子，而是在同一框架中融合LLMs进行基本面因子挖掘，在因子进化时，将因子信息提供给大模型，使其更好的理解因子含义以及规律，生成改进后的因子。

公众号 · 中信建投金工及量化研究团队

资料来源：中信建投

PART 2

LLMs 进化结构

公众号 · 中信建投金工及量化研究团队

因子生成

随机法：这种方法通过随机方式构造因子结构，主要用于启发式算法中的种群初始化。在生成个体时，我们会限制其结构的复杂度以及量纲的合法性，以确保因子具有简洁性并保持较高的可解释性。

枚举法：与之前openfe算法生成因子一致，在因子生成过程中通过设定因子结构的约束条件，如 $(a+b/c+d)$ ，在给定的子空间内进行全局搜索，以期找到局部最优解。

领域知识：这种方法依赖于专家的主观经验，通过专业知识构造一系列基本面因子。然后利用启发式算法不断优化这些因子，结合剪枝和基因结构分析等技术，筛选出适应度较高的基因及个体。接着，通过枚举法合成新的因子个体，并从中挑选出表现优异的个体。

公众号 · 中信建投金工及量化研究团队

资料来源：中信建投

因子计算


两层因子计算结构, 自动处理因子量纲, 频率, 公告期等问题。

第一层：原始财务数据之间的计算。包括资产负债表、现金流量表、利润表以及各种财务指标。将现金流量表和利润表等时间段数据统一转换为单季度数据，按照公告期计算TTM/YOY/QOQ等

第二层：不同频率因子的结合。在处理不同频率的数据时，首先对低频数据按照信息发布日期进行隐式的频率转换（PIT），将其转换为高频数据，然后再与其他高频数据进行计算。

量纲限制:

不同量纲之间数据计算设置相应的规则。量纲类型包括，元（营收，净利润等），无量纲（ROE,PE等），市值（总市值，流动市值等）



资料来源：中信建投

公众号·中信建投金工及衍生品研究团队

因子计算

算子：

包括元素，时序，截面三类算子

算子会对应相应的量纲规则

m代表基本面数据, v代表常数项, 取值为1, 2, 4, 8, 12. 对于季频因子, 常数项单位为季度, 取值从一个季度到三年, 如果为日频因子, 单位为月, 时间长度从一个月到一年

[illegible]

资料来源：中信建投

公众号·中信建投金工及策略研究团队

因子计算

Cython+流式计算加速+双层算子:

传统groupby+rolling apply计算因子：时间复杂度为： $O(M \times T \times N)$ ，M为股票数量，T为时间长度，N正比于Rolling的长度，例如计算5000只股票5年的20日PE平均值，大约需要 $5000 \times 1250 \times 20$ 次运算。

流式计算：基于已有结果进行更新。时间复杂度 $O(M \cdot T)$ ，每次更新的时间复杂度为 $O(1)$ ，相比传统方式，效率提升 N 倍。

以ts_regression_slope算子为例，如果使用传统的scipy.stats.linregress函数，对一只股票两个因子间进行1000次大小为12的滚动回归，耗时约8.15秒，采用cython+流式计算技术，耗时约0.07秒，效率提升116倍。其中cython带来的提升约为9.6倍，流式计算带来的提升约为12倍。

双层算子：对于长表和宽表，分别构建基于pandas和numpy的两套算子，充分利用pandas的灵活性和numpy的高效性，再结合lazy + cache，进一步提高因子计算效率。

[illegible]

资料来源：中信建投

中信建投金工及量化研究团队

双层算子

长表

s_info_windcode	ann_dt	report_period	
000001.SZ	2014-03-07	2013-12-31	0.008708
	2014-04-24	2014-03-31	0.002554
	2014-08-14	2014-06-30	0.005001
	2014-10-24	2014-09-30	0.007777
	2015-03-13	2014-12-31	0.009711
			...
600981.SH	2023-08-26	2023-06-30	0.009423
	2023-11-10	2023-09-30	0.011470
	2024-03-29	2023-12-31	0.014988
	2024-05-10	2024-03-31	0.001496
	2024-08-30	2024-06-30	0.004871

Pandas groupby计算

不断 resample 极其耗时，初始cache数据resample结果，中间进行惰性计算(Lazily evaluated)

宽表

s_info_windcode	000001.SZ	000002.SZ	000003.SZ	000004.SZ
ann_dt				
2018-01-04	49330.780000	22320.449270	...	NaN
2018-01-09	48121.893270	18807.106020	...	NaN
2018-01-16	49942.228700	18807.106020	...	NaN
2018-01-23	46232.187500	99300.406000	...	NaN
2018-01-30	44880.970200	99300.578120	...	NaN
2018-02-06	22580.275000	91242.801200	...	NaN
2018-02-13	223940.812000	88720.617200	...	NaN
2018-02-18	22870.100700	89000.146000	...	NaN
2018-02-23	220820.912870	90170.126200	...	NaN
2018-02-28	222000.200120	88222.209000	...	NaN

numpy计算

惰性计算(Lazily evaluated): 这是一种常用的设计模式，利用装饰器将Python类中的方法转变为属性，通常用于计算量大，频繁调用，且不带参数的方法，这样在实例化的时候只计算一次，并缓存到属性中，以后直接拿来用就行

资料来源: 中信建投


因子进化-遗传规划算法

遗传规划GP: 树形表达式结合进化算法

对树结构进行交叉变异，子树变异，生成新的子代。

本质上是一种前向随机变异过程，进化主要是通过筛选完成。

锦标赛法+改进后适应度筛选相关性低的个体，增加种群多样性。



资料来源: Quant 4.0: Engineering Quantitative Investment with Automated, Explainable and Knowledge-driven Artificial Intelligence. 中信建投

因子进化-LLMs进化

LLMs进化: 大模型分析因子含义以及规律，生成新的因子

提示词构建:

系统提示词

```
"""
作为专业的量化分析师，你的专长在于深入分析因子含义以及规律以因子相关性系数(IC)表现。用户提供的一组因子及其当前的IC指标，每个因子由特定的因子与基础数据构成。你的任务是对这些因子进行细致的分析，理解其逻辑，目标是在维持因子结构可构造的前提下，通过调整因子或者数据来增强因子的有效性。改进方法可以是：

## 因子替换：例如 add -> sub, ts_mean -> ts_max等
## 数据替换：例如 s_fa_workingcapital -> s_fa_investcapital; 1 -> 2等

注意这里只是举了几个例子，具体如何替换根据你自己的理解进行，可替换的因子和数据参考：\n
"""

"""
改进生成新的因子，目标是实现IC值的显著提升。请确保由新的改进因子，不要给出已有因子，在改进过程中注重实发性和因子的可解释性，避免不必要的复杂度增加。完成优化后，直接输出最终优化的因子表达式的列表，给出50个优化因子，并将形式优化为3500。以便于用户直接调用及后续的分析工作，输出格式为：
{ "优化因子列表":
  { "因子": "****", "改进原因": "****",
    "因子": "****", "改进原因": "****",
    "因子": "****", "改进原因": "****"
  }
}
```

资料来源: 中信建投

因子进化-LLMs进化

用户提示词

"以下是已知的因子及其IC: {} \n, 你上次给出的因子: {} \n 请根据以上信息给出新的改进因子, 不能使用已有因子, 也不要和上次给出和上次相同的因子, 必须给出新的改进因子".format(lln_factor_info, last_info)

其中llm_factor_info为筛选出的表现最好且相关性最高的因子及IC信息, last_info为LLMs上次输出的结果。

输出结果:

```
{
  "优化因子列表": [
    {
      "因子": "ets_max(ets_pct(ediv(eadd(ets_delta(s_gfa_grossprofitmargin, 1), div(empl_ben_payable, dq_mv)), s_gfa_salescashintor), 2), 1)",
      "改进原因": "通过增加ets_max函数, 增强了因子的敏感性和稳定性, 预期能提升IC值。",
      "因子": "ets_regression_resi(ets_slope(ets_pct(acct_payable, 1), 8), eadd(esub(esub(ets_delay(div(s_fa_grossmargin, val_mv), 2), s_fa_yoyetprofit_deducted), s_fa_deductedprofitprofit), div(oper_profit, val_mv), 12)",
      "改进原因": "通过增加ets_regression_resi函数, 提高了因子对数据变化的捕捉能力, 预期能提升IC值。",
      "因子": "ediv(esub(ets_norm(s_fa_equitytotdelt), ccs_rank(tot_shldr_eqr_inc1_min_int), div(cadd(s_fa_workingcapital, s_fa_investcapital), val_mv))),",
      "改进原因": "通过增加ediv函数, 优化了因子的结构, 预期能提升IC值。",
      "因子": "ecs_rank(ediv(ets_delta(div(s_fa_deductedprofit, val_mv), 4), ecs_minmax(ets_mean(s_gfa_yoygr, 12))))",
      "改进原因": "通过增加ecs_rank函数, 提高了因子的区分度和稳定性, 预期能提升IC值。",
      "因子": "div(emul(ets_min_max_diff(s_fa_poe_deducted, 12), cadd(sta_ba_tot, net_cash_flow_inv_act)), val_mv)",
      "改进原因": "通过增加div函数, 优化了因子的结构, 预期能提升IC值。",
      "因子": "ecs_rank(emul(ets_regression_square(s_fa_actogr, ets_regression_resi(s_fa_yoyocf, s_gfa_yoyosales, 2), 2), cts_delay(cts_delay(s_fa_ebit, 4), 4))))",
      "改进原因": "通过增加ecs_rank函数, 提高了因子的区分度和稳定性, 预期能提升IC值。",
      "因子": "ecs_minmax(ets_min(ccs_rank(oper_profit), 2))",
      "改进原因": "通过增加ecs_minmax函数, 增强了因子的敏感性和稳定性, 预期能提升IC值。",
      "因子": "ets_slope(ecs_norm(ets_pct(cts_min(undistributed_profit, 1), 1), 8)",
      "改进原因": "通过增加ets_slope函数, 提高了因子的区分度和稳定性, 预期能提升IC值。",
      "因子": "ets_max(ecs_norm(ets_min_max_diff(s_fa_taxtoebt, 8), 4)",
      "改进原因": "通过增加ets_max函数, 增强了因子的敏感性和稳定性, 预期能提升IC值。",
      "因子": "ets_min(ccs_rank(cts_max(net_cash_flow_fnc_act, 4), 2)",
      "改进原因": "通过增加ets_min函数, 提高了因子的区分度和稳定性, 预期能提升IC值。"}
  ]
}
```

LLMs能够“理解”因子的含义, 且每次进化均能给出合理原因

资料来源: 中信建投

因子结果-因子表现


Factor Zoo 数据库

```
factor_id    factor_name
factor_zoo_0  ts_min(ts_pct(div(add(ets_delta(s_gfa_grossprofitmargin, 1), div(empl_ben_payable, dq_mv)), s_gfa_salescashintor), 2), 1)
factor_zoo_1  div(sub(ets_norm(s_fa_equitytotdelt), ccs_rank(tot_shldr_eqr_inc1_min_int), div(cadd(s_fa_workingcapital, s_fa_investcapital), val_mv))
factor_zoo_2  ccs_rank(ediv(ets_delta(div(s_fa_deductedprofit, val_mv), 4), ecs_minmax(ets_mean(s_gfa_yoygr, 12))))
factor_zoo_3  ccs_minmax(div(ts_max(div(tot_cash_outflows_oper_act, val_mv), 8), div(tot_oper_cost2, val_mv)))
factor_zoo_4  ts_pct(div(add(surplus_zrrv, ts_slope(tot_surplus_zrrv), 2), val_mv), 1)
factor_zoo_5  ts_regression_resi(ts_slope(ts_pct(acct_payable, 1), 8), add(sub(ets_delay(div(s_fa_grossmargin, val_mv), 2), s_fa_yoyetprofit_deducted), s_fa_deductedprofitprofit), div(oper_profit, val_mv), 12)
factor_zoo_6  ccs_rank(ediv(ets_delta(div(s_fa_deductedprofit, val_mv), 4), div(tot_oper_cost2, val_mv)))
factor_zoo_7  sub(div(ts_min(s_fa_workingcapital, s_fa_grossmargin), val_mv), ts_regression_square(ets_slope(ts_mean(s_fa_ffcf, 1), 4), ts_min(sub(ts_resi(s_fa_ffcf, 12), add(tot_cur_assets, cap_zrrv), 1), 2)
factor_zoo_8  ccs_minmax(ets_delta(div(sub(ets_pct_admin_exp, s_fa_grossmargin), val_mv), 2)
factor_zoo_9  ts_min(ts_pct(add(ets_delta(s_fa_deductedprofit, add(tot(ts_slope(tot(s_fa_extraordinary, 12), 12), tot(s_fa_deductedprofit)), val_mv), div(tot_shldr_eqr_inc1_min_int, val_mv), 1), 2)
factor_zoo_10 add(div(add(s_fa_deductedprofit, add(tot(ts_slope(tot_shldr_eqr_inc1_min_int, 12)), ts_max(ts_max(ts_min(s_fa_workingcapital, 8), 1), 1)), val_mv), ts_resi(div(ts_min(tot_shldr_eqr_inc1_min_int, 2), val_mv), 8)
factor_zoo_11 add(div(add(s_fa_deductedprofit, add(tot(ts_slope(tot_shldr_eqr_inc1_min_int, 2), ts_max(ts_max(ts_min(tot_shldr_eqr_inc1_min_int, 8), 1), 1)), val_mv), ts_resi(div(ts_min(tot_shldr_eqr_inc1_min_int, 2), val_mv), 8))
```

	IC	ICIR	今年以来IC	今年以来IR
factor_zoo_0	0.0400	0.4338	0.0457	0.0987
factor_zoo_1	0.0357	0.3352	0.0263	0.1154
factor_zoo_2	0.0367	0.3181	0.0622	0.2019
factor_zoo_3	-0.0482	-0.6713	-0.0639	0.0742
factor_zoo_4	0.0596	0.4346	0.0941	0.1735
factor_zoo_5	0.0396	0.5466	0.0640	0.0997
factor_zoo_6	-0.0499	-0.6248	-0.0599	0.1359
factor_zoo_7	0.0444	0.7037	0.0334	0.0492
factor_zoo_8	-0.0398	-0.3476	-0.0374	0.1332
factor_zoo_9	0.0816	0.6777	0.1500	0.1533
factor_zoo_10	0.0451	0.7269	0.0647	0.0571
factor_zoo_11	0.0630	0.4575	0.0812	0.1536

资料来源: 中信建投

因子结果-因子表现



资料来源: 中信建投

因子结果-因子表现



资料来源：中信建投

公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

因子结果-模型回测

训练模型：LightGBM
数据集：17年开始全A数据，3年训练集，1年验证集，3个月滚动训练
因子：factor zoo 12个因子
回测区间：2021.1 – 2024.10
调仓频率：月初调仓
持仓数量：100只



收益指标	ALPHA	累计收益	年化收益	夏普比率	信息比率	索提诺比	詹森阿尔	特雷诺比	胜率	正收益期	BETA	年化波动	跟踪误差	下行风险	在险价值	最大回撤	最大回撤形成期	最大回撤修复期	连续下跌最大幅度	R-Square
组合	68.37%	53.65%	12.40%	0.47	1.34	0.32	0.17	0.11	51.73%	479	1.02	23.33%	0.78%	2.12%	-2.17%	-31.53%	73	147	-19.80%	0.72
业绩基准	0.00%	-14.72%	-4.24%	-0.30	--	-0.18	0.00	-0.06	49.35%	457	1.00	19.43%	0.00%	1.97%	-1.92%	-39.33%	523	null	-12.86%	1.00

资料来源：ifind, 中信建投


公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

因子结果-模型回测

训练模型：LightGBM
数据集：17年开始全A数据，3年训练集，1年验证集，3个月滚动训练
因子：openfe 60个因子
回测区间：2021.1 – 2024.10
调仓频率：月初调仓
持仓数量：100只



收益指标	ALPHA	累计收益	年化收益	夏普比率	信息比率	索提诺比	詹森阿尔	特雷诺比	胜率	正收益期	BETA	年化波动	跟踪误差	下行风险	在险价值	最大回撤	最大回撤形成期	最大回撤修复期	连续下跌最大幅度	R-Square
组合	89.83%	74.11%	16.29%	0.55	1.09	0.41	0.20	0.15	55.51%	514	0.99	26.86%	1.19%	2.28%	-2.46%	-42.29%	24	null	-37.06%	0.51
业绩基准	0.00%	-14.72%	-4.24%	-0.30	--	-0.18	0.00	-0.06	49.35%	457	1.00	19.43%	0.00%	1.97%	-1.92%	-39.33%	523	null	-12.86%	1.00

资料来源：ifind, 中信建投

公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

因子结果-模型回测

训练模型: LightGBM
数据集: 17年开始全A数据, 3年训练集, 1年验证集, 3个月滚动训练
因子: factor zoo 12个因子 + openfe 60个因子
回测区间: 2021.1 – 2024.10
调仓频率: 月初调仓
持仓数量: 100只



收益指标	ALPHA	累计收益	年化收益	夏普比率	信息比率	索提诺比	詹森阿尔	特雷诺比	胜率	正收益期	BETA	年化波动	跟踪误差	下行风险	在险价值	最大回撤	最大回撤	最大回撤	连续下跌	R-Square
组合	93.50%	78.77%	17.13%	0.65	1.51	0.46	0.21	0.16	53.78%	498	1.00	23.98%	0.89%	2.14%	-2.26%	-32.05%	88	127	-19.14%	0.65
业绩基准	0.00%	-14.72%	-4.24%	-0.30	--	-0.18	0.00	-0.06	49.35%	457	1.00	19.43%	0.00%	1.97%	-1.92%	-39.33%	523	null	-12.86%	1.00

资料来源: iFind, 中信建投

公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

PART 3

总结

公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

总结

本文在基本面因子挖掘统一框架的基础上, 融入了LLMs进化模型, 通过LLMs“理解”因子背后的含义以及逻辑, 进化出更加符合人类要求的因子。

通过实际结果可以看出, 在原有因子的基础上, LLMs提供了更多的可能性。

将Factor Zoo 的因子与Openfe的因子进行对比, 可以看出, 更加偏向基本面的Factor Zoo 因子结果明显更加稳定, 将两者融合之后, 收益和稳定性均有明显提升。

Factor Zoo 数据库目前也已经开始定期更新, 欢迎联系我们获取账号。

公众号·中信建投金工及量化研究团队



中信建投证券
CHINA SECURITIES

风险提示

本报告中所有数据结果是基于历史统计结果的展示，未来有可能发生风格切换导致因子失效的风险。模型运行存在一定的随机性，初始化随机数种子会对结果产生影响，单次运行结果可能会有一定偏差。历史数据的区间选择会对结果产生一定的影响。模型参数的不同会影响最终结果。模型对计算资源要求较高，运算量不足会导致结果存在一定的欠拟合风险。本文所有模型结果均来自历史数据，模型存在统计误差，不保证模型未来的有效性，对投资不构成任何建议。

分析师介绍

姚紫薇，金融工程及基金研究首席分析师。上海财经大学管理学硕士，厦门大学统计学学士，在基金研究、资产配置、产品设计、财富管理等领域均有长期深入研究。曾担任招商证券基金评价业务负责人，多次获得“新财富”金融工程方向前三（团队核心成员）。

王超，南京大学粒子物理博士，曾担任基金公司研究员，券商研究员，有丰富的研究和投资经验，2021年加入中信建投证券研究所，主要负责量化多因子选股。

证券研究报告名称：《“逐鹿”Alpha专题报告（二十三）——融合LLMs进化的基本面因子挖掘统一框架》

对外发布时间：2024年11月6日

报告发布机构 中信建投证券股份有限公司

本报告分析师：

姚紫薇

SAC编号：S1440524040001

王超

SAC编号：S1440522120002

免责声明：

【中信建投金工及基金研究团队】

本订阅号（微信号：中信建投金工及基金研究团队）为中信建投证券股份有限公司（下称“中信建投”）

研究发展部金工及基金研究团队运营的唯一订阅号。

本订阅号所载内容仅面向符合《证券期货投资者适当性管理办法》规定的机构类专业投资者。中信建投

专题研究 · 目录

上一篇

【中信建投金工及基金研究】多层次主动权益基金池体系构建

下一篇

基于宏观状态识别的多资产配置ETF组合

