

量化专题



- 报告摘要 -

SUMMARY

► 对于深度学习类的高换手组合，**vwap**成交要好于收盘价成交，选择准确的交易时点可以带来组合收益增厚。

以我们在之前的报告《深度学习模型如何控制策略风险？》中构建的元学习风控因子在中证800内的多头组合为例，组合换手率约为年化单边24倍左右。vwap成交下年化超额收益率为19.1%，收盘价成交下只有16.5%。我们统计今年以来所有股票的日内最低价到收盘价平均涨幅为1.86%，中位数为1.19%；从日内最高价到收盘价的跌幅平均为1.96%，中位数为1.46%，在这之中，若能选择正确的交易时点，则可以为组合提供显著的收益增厚。

► 传统线性因子及事件的交易时点选择效果不明显。

我们取股票5分钟频数据计算10个技术因子，计算因子的时序IC以及信号平均多空收益，并无显著收益。线性指标触发的事件也无法获得显著受益。原因可能有传统线性指标较为拥挤，漏掉集合竞价信息可能对因子准确率产生影响，数据粒度不够细或交易信号滞后等导致价格趋势跟踪过于粗糙，等等。因实时level2数据较难获取，本篇报告着重针对前两个原因进行改进。

► 利用深度学习对于每一个交易时点单独建模预测5分钟后至收盘收益，交易时点选择显著优于传统线性因子。

我们应用ALSTM模型预测股票未来五分钟至当天收盘的收益率，用个股过去最多240个5分钟频的量价数据作为输入，高开低收成交量共6个指标，预测5分钟后的节点至收盘的收益，并在每个时间截点单独建模，信号平均多空收益率0.23%，显著优于线性因子。随后在模型中加入当天集合竞价的level2因子以及部分弱有效技术因子作为嵌入输入，模型信号平均多空收益提升至0.26%。

► 利用SAC强化学习模型进行实时交易决策，可以进一步增厚组合收益。

在股票市场中，强化学习对于高频数据的输入更加敏感，适合制定高频交易决策，SAC强化学习因其优秀的避免过拟合机制而被广泛应用至交易决策中。我们根据当前时间，将预训练好的46个深度学习模型对应特定时点的预测状态以及截面因子输入强化学习，通过多头注意力网络将二者结合，输入强化学习中进行在

线交易决策，最终，策略函数将输出每个时间点对于每只股票的交易信号。强化学习信号平均多空收益0.34%，14：00-15：00胜率最高，中午至14：00间收益最高。

► 将强化学习信号应用在投资组合与指数中效果显著。

利用一定规则进行交易回测，SAC强化学习因子多头组合的年化超额收益率提升至较收盘价提升7.6%，较vwap成交提升5%，提升显著。但相比理论提升较低，这可能是由于部分股票没有成交信号，且取第一个信号时有效性相对较弱等原因。将个股信号合成至股指中，在沪深300，中证500，中证1000平均收益分别为10.3，10.9，11.8bps，在午盘时段收益较高。根据午盘时段估值多空信号计算沪深300日内择时累计收益，年均累计收益14.3%，胜率53.8%，赔率尚可。


01 分钟频因子的日内交易信号

CHAPTER

1.1 日内交易时点选择的意义

在股票投资中，选择合适的交易时机和价格能够显著提升投资组合收益率。相对于每天的收盘价，在调仓时选择低于收盘价的时点买入或者高于收盘价的时点卖出可以帮助投资者获得投资组合的收益增厚。在一般的策略回测中，我们常用vwap（成交量加权均价）来模拟当天的成交价，vwap 是衡量交易质量的一个重要基准，因为它反映了一天内交易价格的加权平均水平。2024年以来vwap与收盘价格相差6个基点，差异微乎其微，且分布基本服从正态分布。


图1：2024 年以来 vwap 与收盘价的价差分布



资料来源：Wind，民生证券研究院绘制

用一个具体例子测试一个高换手投资组合下，不同价格的收益差距。以我们在之前的报告《深度学习模型如何控制策略风险？》中构建的元学习风控因子在中证800内的多头组合为例，组合换手率约为年化单边24倍左右。我们分别测算回测区间内，每周第一个交易日调仓，费用双边千分之三的设置下，vwap成交与收盘价成交的收益区别：

图2: vwap 成交与收盘价成交的收益区别




资料来源: Wind, 民生证券研究院绘制

vwap成交的年化超额收益率为19.1%，收盘价成交下则只有16.5%。结果表明，vwap成交要略好于收盘价成交。一般来说深度学习因子对于即时信息的预测能力更好，均价反映了股价一天的平均表现，而收盘价较均价反映更加靠后的信息，故收盘价成交表现不如均价。但在其他类组合如优秀基本面组合中，随着换手率降低，vwap成交与收盘价成交差距可能进一步缩小。


从最低价至收盘价或者从最高价到收盘价间都有充分的收益空间。我们统计近一年内所有股票的日内最低价到收盘价平均涨幅为1.86%，中位数为1.19%；从日内最高价到收盘价的跌幅平均为1.96%，中位数为1.46%。

图3: 日内最低价至收盘价收益分布



资料来源: wind, 民生证券研究院

图4: 日内最高价至收盘价收益分布



资料来源: wind, 民生证券研究院

故我们可以看出，若能选择日内正确的交易时点，可以在不改变投资组合本身持仓的情况下，通过更合理的成交价格以提升组合收益。

1.2 5分钟频简单量价因子的日内择时效果

我们从分钟频数据出发，试图找出对日内交易时点有预测作用的信号，以打败收盘价成交。一个自然的想法是用常见的日频技术指标算法在分钟频数据上进行应用。考虑到计算资源的稀缺性以及分钟频数据的庞大，我们取股票5分钟频数据计算10个技术因子，考虑到股票开盘价格变动迅速，成交成功率相对较低，我们取9:35为每天首个信号计算截止点，作为5分钟后的交易决策参考。因子具体定义如下：

表1：线性技术指标构建方式

名称	含义	计算方式	方向
MA_24	移动平均线	过去24期收益移动平均	-1
EMA_24	指数移动平均线	过去24期收益指数移动平均	-1
MA_5_48	收益动量放大	过去5期均价/过去48期均价	-1
VR	成交量比率	在过去24期中，价格上升时的成交量总和/价格下降时的成交量总和	-1
RSI	相对强弱指数	过去24期价格平均上升幅度/平均下降幅度	1
Vol_5_48	成交量放大	过去5期平均成交量/过去48期平均成交量	-1
ADL	能量潮	价格变动比例乘以成交量的累计求和	-1
MACD	MACD	过去12期EMA-过去24期EMA的9期EMA	-1
Vol_std_12	成交量波动率	过去12期对数成交量波动率	-1
ncskew	负偏度系数	负偏度系数	1

资料来源：wind，民生证券研究院

我们计算因子的时序IC与到收盘价的预期多空收益来评估因子的日内择时效果。因子的时序IC定义为每只股票在当天每个时刻因子值与五分钟后至收盘收益的相关性，即每只股票每天都有一个IC。对于多空收益，我们首先需要有一个规则将因子值转化为多空信号，一个自然的想法是计算因子在最近一段时间的分位数以判断其股价是否在高位或者低位。我们计算当前因子值在过去960期（即20个交易日）的40%及60%分位数，若指标为正向，小于40%分位数则发出买多信号，大于60%即发出卖空信号；若指标为反向则相反。回测从2019年开始，剔除新股，ST股与每日的涨跌停股票。10个技术指标的回测结果如下：

表2：高频线性技术指标表现

名称	含义	IC均值	平均多空收益
MA_24	移动平均线	-0.013	0.02%
EMA_24	指数移动平均线	-0.011	0.02%
MA_5_48	收益动量放大	-0.021	0.05%
VR	成交量比率	-0.098	0.06%
RSI	相对强弱指数	0.109	0.09%
Vol_5_48	成交量放大	-0.073	0.05%
ADL	能量潮	-0.008	-0.01%
MACD	MACD	-0.055	0.03%
Vol_std_12	成交量波动率	-0.084	0.04%
ncskew	负偏度系数	0.134	0.05%

资料来源：Wind，民生证券研究院绘制

从结果来看，10个因子的平均IC都较为显著，但平均多空收益较低，无法显著跑赢收盘价。

1.3 5分钟频简单K线事件的日内择时效果

除根据因子信号的时序阈值进行日内买卖时点选择外，事件型策略也可以产生多空信号。我们在前文提到的因子基础上建立了4个事件型策略，事件多空信号定义与每次事件的平均多空收益如下：

表3：高频 k 线事件的日内择时效果

多头事件信号	空头事件信号	平均多空收益
价格高于布林带中轨且RSI超卖	价格低于布林带中轨且RSI超买	0.02%
MACD金叉	反向MACD金叉	0.02%
价格接近布林带下轨且J小于20	价格接近布林带上轨且J大于80	0.05%
价格大于MA_24且VROC>20%	价格小于MA_24且VROC<-20%	0.06%

资料来源：Wind，民生证券研究院绘制

综上所述，简单线性的因子型策略与事件型策略都很难相对收盘价有明显超额收益，尤其在考虑到交易滑点与大体量投资组合的冲击成本后。原因可能有以下几点：

1. 信号拥挤从而导致传统线性指标失效：许多投资者利用类似信号盯盘进而做出交易决策，导致市场对价格反应迅速，传统线性指标失效。
2. 漏掉集合竞价信息无法考虑股价跳开：线性因子最多考虑过去48期的5分钟k线，但这其中并不包含集合竞价的信息。每日集合竞价决定了当天的开盘价，而集合竞价中价格的波动率与成交量相关性等因素都可能对当天的筹码分布起到影响，漏掉这部分信息可能对因子准确率产生影响。
3. 数据粒度不够细，交易信号滞后等导致价格趋势跟踪过于粗糙：在信号的构建中，我们只用到5分钟频的实时数据，预测五分钟后的交易信号，在这5分钟内，个股的筹码分布可能发生变化。如果基于实时逐笔委托构造信号并减少信号滞后时间，信号很可能更有效。然而，考虑到实时level2数据成本过高以及计算资源的稀缺性，本篇报告中不做这部分的相关讨论。

02 深度学习日内交易时点寻优


CHAPTER

针对1.3中提出的问题，我们尝试探索一些新的方法对日内交易时点进行预测。在过往的报告中，我们在机器学习预测股票收益的方向做出了一些探索与创新，包括深度学习与强化学习等。在下文中，我们将尝试采用此类非线性的方法对交易时点进行预测。

2.1 深度学习模型选择

深度神经网络是一种基于多层神经元的无监督算法，它被广泛应用于计算机视觉、自然语言处理等领域。深度学习的主要神经网络模型包括：卷积神经网络（CNN）、递归神经网络（RNN）、长短时记忆网络（LSTM）、门循环单元网络（GRU）等等。其中LSTM是一种用于处理和预测基于时间的序列数据的递归神经网络（RNN）。相比传统RNN，LSTM可以克服长期依赖问题，能够有效记住长时间跨度的序列信息。LSTM通过其内部结构（输入门、遗忘门和输出门）来控制信息的传递，从而记住或丢弃与预测任务相关或无关的信息。

图5: LSTM 模型结构示意图




资料来源：Alom et al. 《A state-of-the-art survey on Deep Learning Theory and Architectures》，民生证券研究院

根据我们之前对神经网络的研究，我们选用带有注意力机制的LSTM模型，即ALSTM模型进行建模。ALSTM模型最早由Yao Qin等人在2017年IJCAI上发表的论文A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction中提出。ALSTM模型在LSTM模型的基础上加

入了注意力（Attention）机制，注意力机制是一种能够动态选择序列中关键时刻的机制。在时间序列预测中，某些时刻的数据对最终预测的贡献更大，注意力机制通过分配不同的权重来突出这些重要时刻的数据，提高模型的表现。

图6: ALSTM 模型结构示意图




资料来源：Qin et. al. 《A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction》，民生证券研究院

之所以选择ALSTM模型，主要原因有两个。第一，模型的输入序列较长，需要LSTM模型去记住长时间跨度的序列信息，LSTM可以对输入的股票量价时间序列进行特征提取，输出每个时间步的隐藏状态（hidden state），这些隐藏状态代表了模型对每个时间步的记忆，能够在较长的时间序列输入中提取更加有效的特征。第二，通常来说，股票开盘半小时左右的成交较为活跃，价格波动率较大，而注意力机制可以对LSTM的隐藏状态分配不同的权重。通过这些权重，模型可以聚焦于对当前预测任务最有影响的时间步，比如过去几天的开盘，收盘附近某段时间，从而避免LSTM对所有时刻给予相同关注，提升模型的预测能力。

2.2 ALSTM模型预测交易时点

我们应用ALSTM模型预测股票未来五分钟至当天收盘的收益率。用个股过去最多240个5分钟频的量价数据作为输入，高开低收成交量共6个指标，预测五分钟后的节点至收盘的收益。以早上9：35分的模型为例，我们预测每只股票9：40到收盘的收益率，数据结构及模型示意图如下。

图7: ALSTM 模型示意



资料来源：民生证券研究院绘制

需要注意的是，我们需要对每一个5分钟时点的预测单独建模。原因主要有两个：第一，不同时点的预测标签长度不一致，与我们在过往报告中的深度学习预测股票未来n日收益不同，在日内随着预测时点向后推移，我们的预测标签窗口会渐渐缩短。9：35分的模型预测了未来230分钟的收益，下午14：50的模型只预测最后5分钟收益，预测含义不一致，故须分开建模；第二，对于不同时点的预测模型，注意力权重的位置不同，由于深度神经网络的输入是时序数据，每一个时间步的位置都具有其意义，比如对于9：35分的模型，9：30分的输入是倒数第二个时间步，而对于9：40分的模型就是倒数第三个时间步，而ALSTM对于每一个时间步的位置权重固定，所以不同时点的模型需要重新训练每个时间步的注意力权重。按照数据截止时点来算，从每日9：35至14：50，我们共需训练46个模型。并且随着时点向后推迟，数据的输入窗口也不一致。由于早上预测的时间窗口较长，我们采用240的时序窗口；随后每往后5分钟，就将窗口长度减少4，则14：50分模型的输入窗口为60。考虑到数据量，我们每次采用过去3年数据进行训练，年度滚动训练，样本外从2019年开始。其他训练设置与模型细节如下图：


图8：模型参数及训练设置

特征处理	特征X：最多过去240个5分钟频的高、开、低、收、成交额、成交量、维度为(n, 240, 6)，随着模型时间截点往后，采用更短序列，14：50的模型采用过去60个5分钟频量价作为输入 特征处理，即(n, 60,6), 对过去window的量价指标做MinMax标准化 标签y：五分钟后至收盘收益
模型结构	ALSTM: input_size=6, hidden_size=64, activation=relu Dropout: dropout概率为0.1 MLP: 全连接层，输入维度64，输出维度1
训练参数	损失函数：MSE batch_size: 每天所有股票，剔除涨跌停，新股及ST; max_epoch: 100，早停: 20, min_epoch:30 学习率：0.001，优化器：Adam

资料来源：民生证券研究院绘制


与第一节中的线性信号相同，我们继续利用时序IC与每次信号的平均多空收益衡量信号表现。因子时序IC在2019年以来的平均值为0.095，稳定性较高。模型每日在所有股票上的IC胜率超过60%，而每日IC为所有股票时序的平均，故较为稳定。我们以±5个基点为阈值根据预期收益制定多空信号，即预测5分钟后至收盘收益大于0.05%则发出买多信号，小于-0.05%则发出卖空信号。2019年以来平均每次信号的平均多空收益0.23%，相比线性因子有显著提升。

图9：ALSTM 模型信号时序 IC



资料来源：wind，民生证券研究院

图10：ALSTM 模型信号多空收益




资料来源：wind，民生证券研究院

2.2 对于 ALSTM模型的改进

在前文中我们提到过，分钟频数据不包含集合竞价信息，使得模型缺少了对日间股价跳跃的认知，故我们对于原模型进行改进，加入集合竞价信息的输入。具体地，我们采用每日集合竞价level2数据构造的特征，以及第一节中提到的部分弱有效技术因子，作为ALSTM的嵌入层输入，模型其他设置不变。示意图如下：

图11: 改进后 ALSTM 模型结构示意图



资料来源：民生证券研究院绘制

集合竞价因子以及线性技术因子算法如下：


表4：集合竞价与线性技术因子列表

名称	含义	计算方式
VR	成交量比率	在过去24期中，价格上升时的成交量总和/价格下降时的成交量总和
RSI	相对强弱指数	过去24期价格平均上升幅度/平均下降幅度
MACD	MACD	过去12期EMA-过去24期EMA的9期EMA
Vol_std_12	成交量波动率	过去12期对数成交量波动率
ncskew	负偏度系数	负偏度系数
OB_BT_ABOR	集合竞价主买率	主动买单的量比，值越大说明主买单的比率越高
OB_CA2_BOTR	阶段2委买成交率	集合竞价第2个阶段的委买单最终撮合成功的占比，值越大说明委买单有效性更高
SS_RD_RS	收益率偏度	收益率的偏度，值越大说明分布更加右偏，正收益比重越大
OB_CA1_CAOA	阶段1委卖撤单活跃度	集合竞价第1个阶段委卖单的撤单操作频率，值越大说明委卖单撤单的频率越高
OB_CA2_LAOR	阶段2大单委卖率	集合竞价第2个阶段委卖大单的量比，值越大说明委卖大单的量比越高
SS_RD_TS	趋势强度	拟撮合价格的波动与路径之比，值越大说明价格趋势越强
SS_OB_IIMC	买卖单流动性不平衡度	买卖单交易成本之差，值越大说明股票更容易买而不容易卖

资料来源：同花顺，民生证券研究院绘制


改进后模型效果有所提升，信号平均时序IC提升至13.3%，信号平均多空收益提升至26.3bps。假设一个双边年化换手率10倍的随机投资组合，在不考虑滑点及冲击成本等因素的影响下，改进ALSTM日内预测因子平均可提升其2.63%的年化收益。

图12: 改进 ALSTM 模型信号时序 IC



资料来源：wind，同花顺，民生证券研究院

图13: 改进 ALSTM 模型信号多空收益



资料来源：wind，同花顺，民生证券研究院

03 SAC强化学习日内交易时点寻优

CHAPTER

3.1 SAC强化学习

相较于深度学习，强化学习往往在高频率的实时决策中更加有效，因为强化学习的在线模式可以不断更新模型，适应市场变化规律。在股票市场中，之前的尝试表明，强化学习在周频以上的模型中效果一般，对于高频数据的输入更加敏感，适合制定高频交易决策。故在本篇报告中，我们尝试利用强化学习进行实时交易决策，输出股票买卖信号。

图14: 改进后 StockFormer 模型结构





图15: SAC 模型结构



SAC将输出策略函数 π ，对于每只股票决定未来5分钟的买入/卖出决策。SAC方法包括一个演员网络(π_θ)和两个评论家网络($Q\phi_1$ 和 $Q\phi_2$)，演员网络根据当前策略选择动作 $a_t = \pi_\theta(s_t)$ ，我们定义 r_t 为做出交易决策5分钟之后至收盘收益，抽样后更新两个critic网络，损失函数为：

$$\min_{\phi, \psi} \mathbb{E}_{(s_t, a_t) \sim D} \left[\frac{1}{2} \left(Q(s_t, a_t) - \hat{Q}(s_t, a_t) \right)^2 \right]$$

其中

$$Q = R_t + \gamma \min_{j=1,2} Q_{\phi_j'}(s_{t+1}, a_{t+1}) - \lambda \log \pi_\theta(a_{t+1} | s_{t+1}),$$


R_t 为训练标签，也就是每支股票5分钟后至收盘的绝对收益率。 γ 为折现因子，代表对未来奖励的重视程度，取值范围为0~1。在后续应用中，我们取 $\gamma=0.2$ ，因为我们主要看重即时奖励。而 λ 为熵正则项的权重，保证策略的探索程度，在SAC中这一系数会动态调整。

用重参数技巧采样另一组动作 a_t 后，再用以下损失函数更新策略网络梯度 $J(\pi_\theta)$ ：

$$\min_{\theta} (\lambda \log \pi_\theta(\tilde{a}_t | s_t) - \min_{j=1,2} Q_{\phi_j'}(\tilde{a}_t, s_t))$$

此外，我们延用上篇报告中的多头注意力机制来对强化学习的多个输入状态，即深度学习预测，集合竞价因子及分钟频技术因子进行整合。用一组前馈网络(Forward Feed Network)而不是单个FFN，其中每个FFN单独响应多头(Multi-head)注意力层输出中的一个头(head)，在不改变整体参数数量的情况下，这种机制加强了多头注意力的原始特征解耦能力，有助于在不同子空间中建模多样的时间模式。完整模型结构如下：

图16：SAC 交易决策模型结构




资料来源：民生证券研究院绘制

在最终模型中替换输入为对应时点的深度学习输入及截面因子。由于对日内收益的预测问题对股票间相关状态表示的依赖有所降低，我们不再寻找股票间相关性的信息输入，而是将深度学习模型全部动态输入至强化学习中，即根据当前时间，将预训练好的46个深度学习模型对应特定时点的预测状态以及截面因子输入强化学习，通过多头注意力网络将ALSTM输出的隐藏层与当天集合竞价因子及当时刻的分钟频技术面指标相结合，输入强化学习中进行在线交易决策，最终，策略函数将输出每个时间点对于股票的交易决策（买入，卖出，不变）。

3.2 强化学习模型策略表现

我们将强化学习输出的交易信号进行回测，计算模型输出买入/卖出信号时的平均收益。结果表明，强化学习进一步提升了决策的平均多空收益，模型信号平均多空收益34.1bps，显著打败收盘价成交。

图17： SAC 强化学习模型表现



资料来源：Wind，同花顺，民生证券研究院

分年回测强化学习信号表现，2019，2022年平均多空收益与胜率较高，其他年份表现较为接近，且买入信号的平均多头收益小于卖出信号平均空头收益。5年平均多空收益0.34%，显著打败收盘价成交，对于一个年化12倍换手率的投资组合，交易信号平均使其获得4%的收益提升，效果显著。

表5： SAC 强化学习模型表现

年份	平均每笔多空收益	多空胜率	买入信号平均收益	卖出信号平均收益
2019	0.34%	68%	0.34%	0.34%
2020	0.28%	59%	0.29%	0.28%
2021	0.32%	63%	0.30%	0.35%
2022	0.37%	69%	0.35%	0.41%
2023	0.33%	61%	0.29%	0.35%
2024/7/26	0.41%	60%	0.37%	0.45%
平均	0.34%	64%	0.31%	0.37%

资料来源：Wind，同花顺，民生证券研究院

模型不同时段胜率与收益差距明显。进一步测算策略在不同时段以及不同宽基内的信号胜率及信号平均多空收益，我们定义胜率为出现买入或卖出信号时，获得相对收盘正收益的频率，结果表明14：00–15：00胜率最高，而中午至14：00间收益最高。而早间时段因价格波动较快，数据粒度不够细等原因，信号及胜率都相对较低，但仍然可以作为交易决策及信号。此外，在不同宽基中，胜率及多空收益并无显著差别。

表6： 强化学习策略分时分域信号胜率

时段	沪深300	中证500	中证800	中证1000	全部
9: 30-10: 00	54.9%	54.7%	54.8%	54.4%	59.4%
10: 00-11: 00	57.3%	56.9%	57.0%	56.7%	61.2%
11: 00-11: 30	60.1%	59.2%	59.6%	59.0%	63.5%
13: 00-14: 00	64.1%	63.0%	63.4%	62.0%	66.5%
14: 00-15: 00	74.3%	70.0%	71.3%	67.4%	71.3%

资料来源：wind，同花顺，民生证券研究院

表7： 强化学习策略分时分域信号多空收益


时段	沪深300	中证500	中证800	中证1000	全部
9: 30-10: 00	0.22%	0.25%	0.24%	0.28%	0.26%
10: 00-11: 00	0.26%	0.29%	0.28%	0.32%	0.31%
11: 00-11: 30	0.30%	0.34%	0.33%	0.37%	0.36%
13: 00-14: 00	0.33%	0.36%	0.34%	0.38%	0.37%
14: 00-15: 00	0.33%	0.33%	0.33%	0.33%	0.33%

资料来源：wind，同花顺，民生证券研究院

我们应用一个具体的投资组合对交易信号进行有效性测试。对于在第一节中提到的元学习风控因子的中证800多头等权组合，在每周第一个交易日调仓时，我们取每日上午10：00—11：30的第一个卖出信号对应

价格作为卖出价格，取每日下午13：00—14：30的第一个买入信号对应价格作为买入价格。因为有可能在上午时段无卖出信号，则为了控制仓位不大于100%，规定下午买入股票数量不大于上午的卖出股票数量。若14：30后仍然有未调仓股票，则暂时按照收盘价进行测算。应用收盘价与强化学习交易信号的组合收益如下图：

图18： SAC 强化学习交易信号提升



资料来源：Wind，同花顺，民生证券研究院

利用上述规则进行回测，组合年化超额收益率提升至24.1%，较收盘价提升7.6%，较vwap成交提升5%，提升显著。理论上，对于一个年化双边换手率48倍的组合，收益提升大约在16%左右，而在应用上述规则后收益提升有所降低，这可能是因为部分股票没有成交信号，且取第一个信号时有效性相对较弱等。

3.2 强化学习模型策略表现

强化学习对于股票交易时点的预测同样可以应用到宽基指数上。强化学习交易信号在股票投资组合的交易细节上难以回测，实际应用需要根据组合体量与成交量曲线预测决定应用细节，较为复杂。我们因此尝试在宽基指数上构建交易信号，探索指数的日内交易时点预测，从而考虑股指期货上的可能应用。指数本质上与股票的自由流通市值加权相似，所以我们直接根据个股的预测收益按照成分股权重加权计算指数收益的预测，并进行回测。回测结果如下：

表8： 强化学习指数信号表现


指数名称	信号平均多空收益	信号平均胜率
沪深300	10.3bps	61.3%
中证500	10.9bps	62.4%
中证1000	11.8bps	66.7%

资料来源：Wind，同花顺，民生证券研究院

在一天的不同时间内，强化学习信号在指数上的平均多空收益也呈现出先涨后跌的规律，这是因为早上股价水平难以预测，胜率较低，而下午收盘时间价格波动小，即使预测准确也无法获得足够收益，赔率较

低。而午盘时段模型兼具胜率和赔率，可以着重作为参考。以沪深300为例，强化学习信号合成后平均收益规律如下图：


图19：强化学习指数信号分时段收益规律



资料来源：Wind，同花顺，民生证券研究院

按照此效果，可以在每日午盘左右的时间根据股指的多空信号进行股指期货的建仓，在收盘时平仓，赚取股指日内变动的收益。我们假设买卖成本均为万分之一，只计算每日沪深300从13：05到15：00的指数收益变动，按照多空信号计算的沪深300股指日内择时的累计收益曲线如下图：

图20：沪深 300 日内择时累计收益



资料来源：Wind，同花顺，民生证券研究院

策略平均每年累计收益14.3%，最大回撤发生在2022年，为7.4%。收益回撤比大概为2：1，模型总体胜率53.8%，可见赔率尚可。然而，由于实际期货策略须考虑到每天不同时点的基差，资金成本，滑点及佣

04 总结与思考

CHAPTER

在本篇报告中，我们讨论了如何选择交易时点的问题。从高频线性因子的构造，到深度学习预测交易时点至收盘收益，最后利用强化学习进行实时交易决策。利用交易时点选择提升了组合收益，并且在指数上也有一定效果。

对于深度学习类的高换手组合，vwap成交要好于收盘价成交，选择正确的交易时点对于提升组合收益意义重大。以我们在之前的报告《深度学习模型如何控制策略风险？》中构建的元学习风控因子在中证800内的多头组合为例，组合换手率约为年化单边24倍左右。vwap成交的年化超额收益率为19.1%，收盘价成交下则只有16.5%。我们统计近一年内所有股票的日内最低价到收盘价平均涨幅为1.86%，中位数为1.19%；从日内最高价到收盘价的跌幅平均为1.96%，中位数为1.46%，在这之中，若能选择正确的交易时点，则可以为组合提供显著的收益增厚。

传统线性因子及事件的交易时点选择效果不明显。我们取股票5分钟频数据计算10个技术因子，计算因子的时序IC以及信号平均多空收益，并无显著收益。线性指标触发的事件也无法获得显著受益。原因可能有传统线性指标较为拥挤，漏掉集合竞价信息可能对因子准确率产生影响，数据粒度不够细或交易信号滞后等导致价格趋势跟踪过于粗糙，等等。因实时level2数据较难获取，本篇报告着重针对前两个原因进行改进。

利用深度学习对于每一个交易时点单独建模预测5分钟后至收盘收益，交易时点选择显著优于传统线性因子。我们应用ALSTM模型预测股票未来五分钟至当天收盘的收益率，用个股过去最多240个5分钟频的量价数据作为输入，高开低收成交量共6个指标，预测五分钟后的节点至收盘的收益，并在每个时间截点单独建模，信号平均多空收益率0.23%，显著优于线性因子。随后在模型中加入当天集合竞价的level2因子以及部分弱有效技术因子作为嵌入输入，模型信号平均多空收益提升至0.26%。

利用SAC强化学习模型进行实时交易决策，可以进一步增厚组合收益。在股票市场中，强化学习对于高频数据的输入更加敏感，适合制定高频交易决策。SAC强化学习因其优秀的避免过拟合机制而被广泛应用至交易决策中，我们将预训练好的46个深度学习模型之一的预测状态以及截面因子输入强化学习，通过多头注意力网络将二者结合，输入强化学习中进行在线交易决策，最终，策略函数将输出每个时间点对于每只股票的交易信号。强化学习信号平均多空收益0.34%，14:00-15:00胜率最高，中午至14:00间收益最高。

将强化学习信号应用在投资组合与指数中效果显著。利用一定规则进行交易回测，深度学习因子多头组合的年化超额收益率提升至较收盘价提升7.6%，较vwap成交提升5%，提升显著。但相比理论提升较低，这可能是部分股票没有成交信号，且取第一个信号时有效性相对较弱等原因。将个股信号合成至股指中，在沪深300，中证500，中证1000平均收益分别为10.3，10.9，11.8bps，在午盘时段收益较高，可以考虑股指期货类应用。

模型信号在实际应用中情况较为复杂，需要考虑更多因素。由于我们进行测算时使用的是信号产出五分钟后的分钟收盘价作为成交价格，在实际应用中并不总是能达成这个价格，收益可能会有所衰减。若利用逐笔委托数据计算对手价作为成交价格，则可以更加准确。此外，在实际投资组合的应用时需要考虑组合体量造成的冲击成本，滑点等问题，解决这些问题需要更加复杂的测算与精细的数据，我们会在未来完善相关部分的讨论。

量化模型基于历史数据，市场未来可能发生变化，策略模型有失效可能。

报告信息：

叶尔乐 S0100522110002 yeerle@mszq.com

韵天雨 S0100122120002 yuntianyu@mszq.com

本文来自民生证券研究院于2024年10月25日发布的报告《如何利用AI模型寻找日内最佳买卖点？》，详细内容请阅读报告原文。



民生金工 叶尔乐团队



叶尔乐
民生金工首席分析师

复旦大学本硕，曾任职于国盛证券研究所、国泰君安证券研究所，多次获得新财富、水晶球最佳分析师奖



欢|迎|关|注



尔乐量化

民生金工团队将以开放视角与第一性原理量化市场规律、发掘投资机会，欢迎关注！

358篇原创内容

公众号

重要提示

《证券期货投资者适当性管理办法》于2017年7月1日起正式实施，通过本微信订阅号/本账号发布的观点和信息仅供民生证券的专业投资者参考，完整的投资观点应以民生证券研究院发布的完整报告为准。若您并非民生证券客户中的专业投资者，为控制投资风险，请取消订阅、接收或使用本订阅号/本账号中的任何信息。本订阅号/本账号难以设置访问权限，若给您造成不便，敬请谅解。我司不会因为关注、收到或阅读本订阅号/本账号推送内容而视相关人员为客户；市场有风险，投资需谨慎。

免责声明

民生证券股份有限公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。本报告仅供本公司境内客户使用。本公司不会因接收人收到本报告而视其为客户。本报告仅为参考之用，并不构成对客户投资建议，不应被视为买卖任何证券、金融工具的要约或要约邀请。本报告所包含的观点及建议并未考虑个别客户的特殊状况、目标或需要，客户应当充分考虑自身特定状况，不应单纯依靠本报告所载的内容而取代个人的独立判断。在任何情况下，本公司不对任何人因使用本报告中的任何内容而导致的任何可能的损失负任何责任。

上一篇	下一篇
全球资产量化：沙特权益驱动因素和配置逻辑 民生金工	财报重构下的经营现金流拆解及盈利质量刻画 民生金工